Análise Exploratória de dados

dr. Rachid Muleia, Msc. in Statistics

Universidade Eduardo Mondlane
Faculdade de Ciências
Departamento de Matemática e Informática

Julho - Novembro 2019

Análise exploratória de dados (AED)

Refere-se ao processo crítico de fazer uma pesquisa inicial sobre dados, de modo a descobrir padrões, identificar anomalias, testar hipóteses e verificar suposições com a ajuda de estatísticas sumárias e representações gráficas.

Estatísticas descritivas

Antes de prosseguir com qualquer análise, é importante ter uma visão básica sobre a dimensão dos seus dados.

- `dim()` - número de linhas (observações) e colunas (variáveis).
- `head()` - visualizar algumas linhas da base de dados.
- `str()` - conhecer um pouco sobre o tipo de variáveis presentes na base de dados.

Algumas funções que podem ser usadas para calcular algumas estatísticas descritivas

```
summary() # retorna valores como a média, mediana, mínimo...
mean () # média
max(), min() # máximo e mínimo, respectivamente
sd(), var(), # desvio padrão e variancia, respectivamente
corr() # correlacao entre duas ou mais variáveis.
table() # tabela de frequência
```

Para ilustrar o processo da análise exploratória de dados, iremos usar a base de dados sobre a qualidade de vinhos que pode ser encontrada em https://archive.ics.uci.edu/ml/datasets/wine+quality

```r
vinho = read.table('C:/Users/lucp8943/Dropbox/Analise de Dados DMI/Slides Aulas/winequalityred.csv',header=TRUE

dim(vinho)
```

```
## [1] 1599   12
```

```r
head(vinho)
```

```
##   fixed.acidity volatile.acidity citric.acid residual.sugar chlorides
## 1           7.4             0.70        0.00            1.9     0.076
## 2           7.8             0.88        0.00            2.6     0.098
## 3           7.8             0.76        0.04            2.3     0.092
## 4          11.2             0.28        0.56            1.9     0.075
## 5           7.4             0.70        0.00            1.9     0.076
## 6           7.4             0.66        0.00            1.8     0.075
##   free.sulfur.dioxide total.sulfur.dioxide density   pH sulphates alcohol
## 1                  11                   34  0.9978 3.51      0.56     9.4
## 2                  25                   67  0.9968 3.20      0.68     9.8
## 3                  15                   54  0.9970 3.26      0.65     9.8
## 4                  17                   60  0.9980 3.16      0.58     9.8
## 5                  11                   34  0.9978 3.51      0.56     9.4
## 6                  13                   40  0.9978 3.51      0.56     9.4
##   quality
## 1       5
## 2       5
## 3       5
## 4       6
## 5       5
## 6       5
```

Verificar o tipo de variáveis presentes na base de dados usando o comando `str()`

```r
str(vinho)
```

```
## 'data.frame':    1599 obs. of  12 variables:
##  $ fixed.acidity       : num  7.4 7.8 7.8 11.2 7.4 7.4 7.9 7.3 7.8 7.5 ...
##  $ volatile.acidity    : num  0.7 0.88 0.76 0.28 0.7 0.66 0.6 0.65 0.58 0.5 ...
##  $ citric.acid         : num  0 0 0.04 0.56 0 0 0.06 0 0.02 0.36 ...
##  $ residual.sugar      : num  1.9 2.6 2.3 1.9 1.9 1.8 1.6 1.2 2 6.1 ...
##  $ chlorides           : num  0.076 0.098 0.092 0.075 0.076 0.075 0.069 0.065 0.073 0.071 ...
##  $ free.sulfur.dioxide : num  11 25 15 17 11 13 15 15 9 17 ...
##  $ total.sulfur.dioxide: num  34 67 54 60 34 40 59 21 18 102 ...
##  $ density             : num  0.998 0.997 0.997 0.998 0.998 ...
##  $ pH                  : num  3.51 3.2 3.26 3.16 3.51 3.51 3.3 3.39 3.36 3.35 ...
##  $ sulphates           : num  0.56 0.68 0.65 0.58 0.56 0.56 0.46 0.47 0.57 0.8 ...
##  $ alcohol             : num  9.4 9.8 9.8 9.8 9.4 9.4 9.4 10 9.5 10.5 ...
##  $ quality             : int  5 5 5 6 5 5 5 7 7 5 ...
```

Algumas estatísticas descritivas usando a função `summary()`

```r
summary(vinho)
```

```
##  fixed.acidity   volatile.acidity  citric.acid    residual.sugar
##  Min.   : 4.60   Min.   :0.1200   Min.   :0.000   Min.   : 0.900
##  1st Qu.: 7.10   1st Qu.:0.3900   1st Qu.:0.090   1st Qu.: 1.900
##  Median : 7.90   Median :0.5200   Median :0.260   Median : 2.200
##  Mean   : 8.32   Mean   :0.5278   Mean   :0.271   Mean   : 2.539
##  3rd Qu.: 9.20   3rd Qu.:0.6400   3rd Qu.:0.420   3rd Qu.: 2.600
##  Max.   :15.90   Max.   :1.5800   Max.   :1.000   Max.   :15.500
##    chlorides       free.sulfur.dioxide total.sulfur.dioxide
##  Min.   :0.01200   Min.   : 1.00       Min.   :  6.00
##  1st Qu.:0.07000   1st Qu.: 7.00       1st Qu.: 22.00
##  Median :0.07900   Median :14.00       Median : 38.00
##  Mean   :0.08747   Mean   :15.87       Mean   : 46.47
##  3rd Qu.:0.09000   3rd Qu.:21.00       3rd Qu.: 62.00
##  Max.   :0.61100   Max.   :72.00       Max.   :289.00
##     density             pH          sulphates         alcohol
##  Min.   :0.9901   Min.   :2.740   Min.   :0.3300   Min.   : 8.40
##  1st Qu.:0.9956   1st Qu.:3.210   1st Qu.:0.5500   1st Qu.: 9.50
##  Median :0.9968   Median :3.310   Median :0.6200   Median :10.20
##  Mean   :0.9967   Mean   :3.311   Mean   :0.6581   Mean   :10.42
##  3rd Qu.:0.9978   3rd Qu.:3.400   3rd Qu.:0.7300   3rd Qu.:11.10
##  Max.   :1.0037   Max.   :4.010   Max.   :2.0000   Max.   :14.90
##     quality
##  Min.   :3.000
##  1st Qu.:5.000
##  Median :6.000
##  Mean   :5.636
##  3rd Qu.:6.000
##  Max.   :8.000
```

- É notável uma grande diferença entre terceiro quartil e o máximo das variáveis, `fixed.acidity`, `residual.sugar`, `free.sulfur.dioxid`, `total.sulfur.dioxide` (indícios de valores extremos).
- Em todas as variáveis verifica-se que a média é maior que a mediana, exceptuando a variável `quality` (distribuição pode ser assimétrica)

```
library(dplyr)
vinho %>% group_by(quality)%>% summarize(freq=n())
```

```
## # A tibble: 6 x 2
##   quality  freq
##     <int> <int>
## 1       3    10
## 2       4    53
## 3       5   681
## 4       6   638
## 5       7   199
## 6       8    18
```

```
# table(vinho$quality) # produz o mesmo resultado
```

Pode-se notar que maior parte dos vinhos são têm classificação 5 e 6, muito poucos têm classificação 8, e nenhum tem classificação 10.

Frequências: relativas e acumuladas.

```r
prop.table(table(vinho$quality)) # frequência relativa
```

```
##
##           3           4           5           6           7           8
## 0.006253909 0.033145716 0.425891182 0.398999375 0.124452783 0.011257036
```

```r
cumsum(table(vinho$quality)) # frequencia acumulada
```

```
##    3    4    5    6    7    8
##   10   63  744 1382 1581 1599
```

Dados omissos (Missing data/missing cases)

- A análise exploratória também involve a verificação de dados
- No R o dados omissos são representados por `NA`
- Pode-se verificar a presença de valores usando a função `is.na()`, a qual retorna um valor `TRUE` na presença de um valor omisso.

```
# vector com valores omissos
x = c(1:4, NA, 6:7, NA)
x
```

```
## [1]  1  2  3  4 NA  6  7 NA
```

```
is.na(x)
```

```
## [1] FALSE FALSE FALSE FALSE  TRUE FALSE FALSE  TRUE
```

```r
df= data.frame(col1 = c(1:3, NA),
                 col2 = c("this", NA,"is", "text"),
                 col3 = c(TRUE, FALSE, TRUE, TRUE),
                 col4 = c(2.5, 4.2, 3.2, NA),
                 stringsAsFactors = FALSE)

# indentificar NA`s na base de dados
is.na(df)
```

```
##       col1  col2  col3  col4
## [1,] FALSE FALSE FALSE FALSE
## [2,] FALSE  TRUE FALSE FALSE
## [3,] FALSE FALSE FALSE FALSE
## [4,]  TRUE FALSE FALSE  TRUE
```

```r
is.na(df$col4)
```

```
## [1] FALSE FALSE FALSE  TRUE
```

Para identificar a posição dos NAs usa-se a função `which()`, e para saber da quantidade usa-se a função `sum()`

```r
which(is.na(x))
```

```
## [1] 5 8
```

```r
sum(is.na(x))
```

```
## [1] 2
```

Diante de uma base de dados pode-se conhecer o número de valores omissos usando como auxílio a função `colSums()`

```
colSums(is.na(df))
```

```
## col1 col2 col3 col4
##    1    1    0    1
```

Modificar valores omissos

```
x[is.na(x)] = mean(x, na.rm = TRUE)
round(x,2)
```

```
## [1] 1.00 2.00 3.00 4.00 3.83 6.00 7.00 3.83
```

```
df = data.frame(col1 = c(1:3, 99), col2 = c(2.5, 4.2, 99, 3.2))
df[df == 99] <- NA
df
```

```
##   col1 col2
## 1    1  2.5
## 2    2  4.2
## 3    3   NA
## 4   NA  3.2
```

Podemos estar interessados em obter um conjunto de dados sem nenhuma observação omissa. Para tal, é só usar a função `complete.cases` ou `na.omit()`

```r
complete.cases(df) # retorna um vectorlógico indicando quais observações com observaçãoes omissas
```

```
## [1]  TRUE  TRUE FALSE FALSE
```

```r
df[complete.cases(df),]
```

```
##   col1 col2
## 1    1  2.5
## 2    2  4.2
```

```r
# se quisermos ter todas as linhas com dados omissos é só usar o operador "!"

df[!complete.cases(df),]
```

```
##   col1 col2
## 3    3   NA
## 4   NA  3.2
```

```r
# função na.omit exclui todas as linhas com observações omissas

na.omit(df)
```

```
##   col1 col2
## 1    1  2.5
## 2    2  4.2
```

Gráficos

- O R é bastante apreciado devido a sua capacidade de fazer gráficos elagantes.
- Com o R pode-se obter qualquer tipo de gráfico, bastando manipular a função `plot()`
- Gráficos produzidos em R podem ser gravados em vários formatos, `pdf`,`png`, `jpg`...

O R tem algumas funções predifinidas que podem ser usadas para uma rápida exploração de dados.

- `plot()` geralmente usada para diagrama de dispersão
- `barplot()` gráfico de barras
- `hist()` histograma
- `boxplot()` caixa de bigodes

Vamos regressar um pouco a nossa base de dados `vinho` e verificar se existe alguma relação entre algumas variáveis

```
plot(x=vinho$fixed.acidity , y=vinho$citric.acid)
```

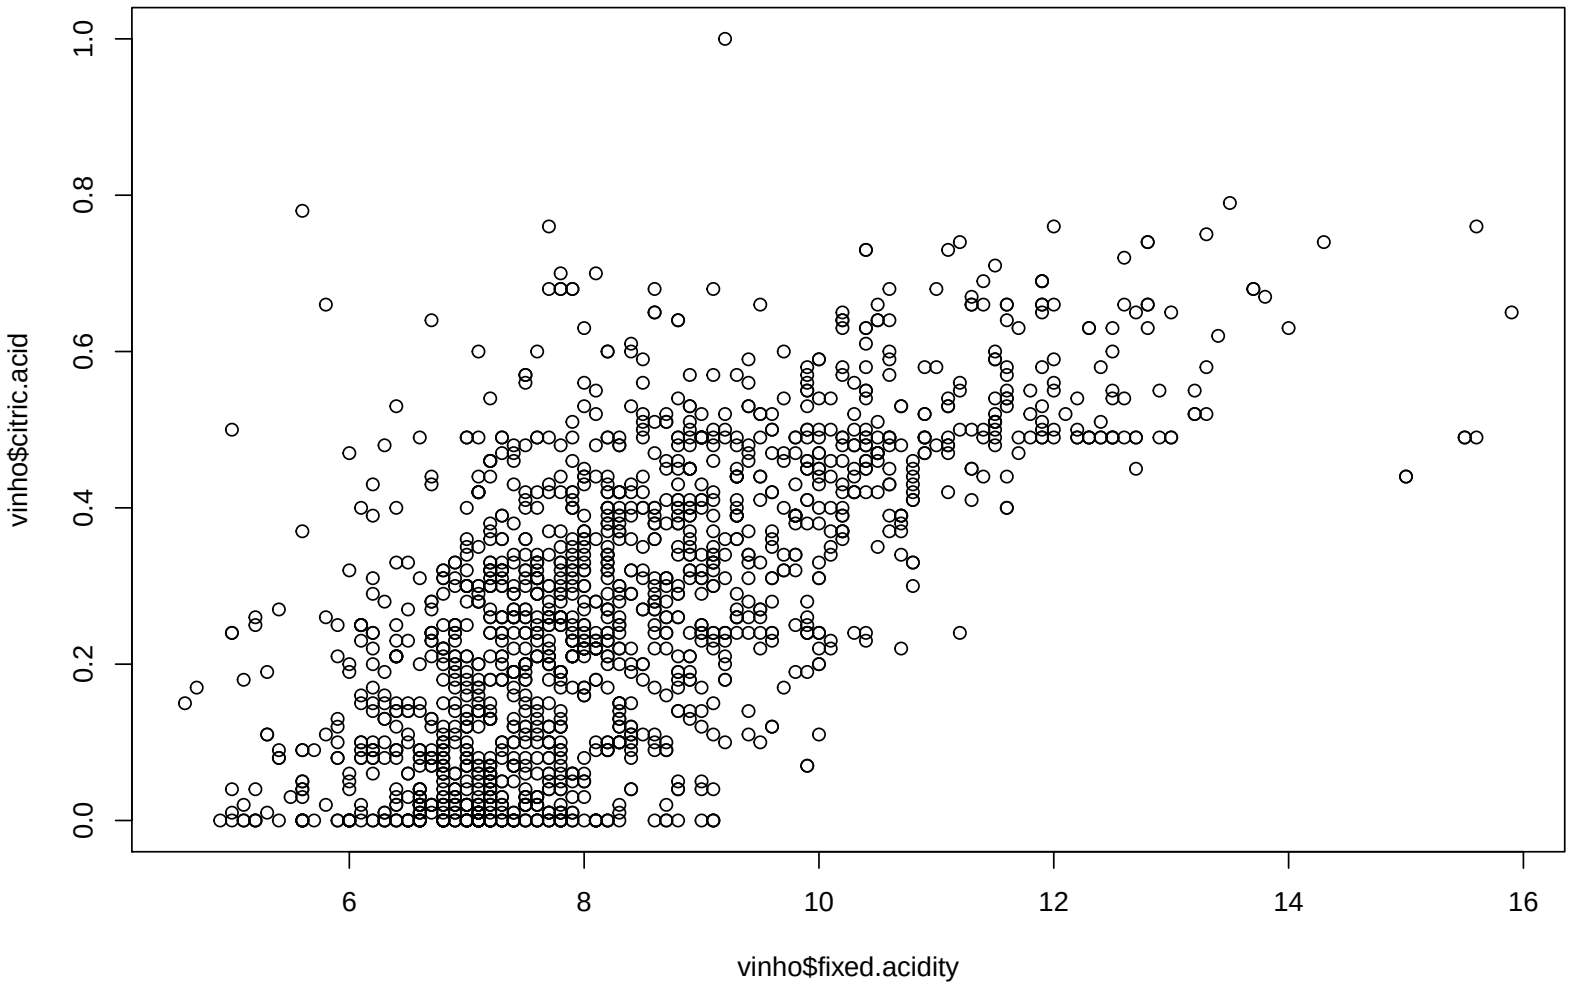

Pode-se diferenciar as cores para cada classificação

```
plot(x=vinho$fixed.acidity , y=vinho$citric.acid, col=vinho$quality)
```

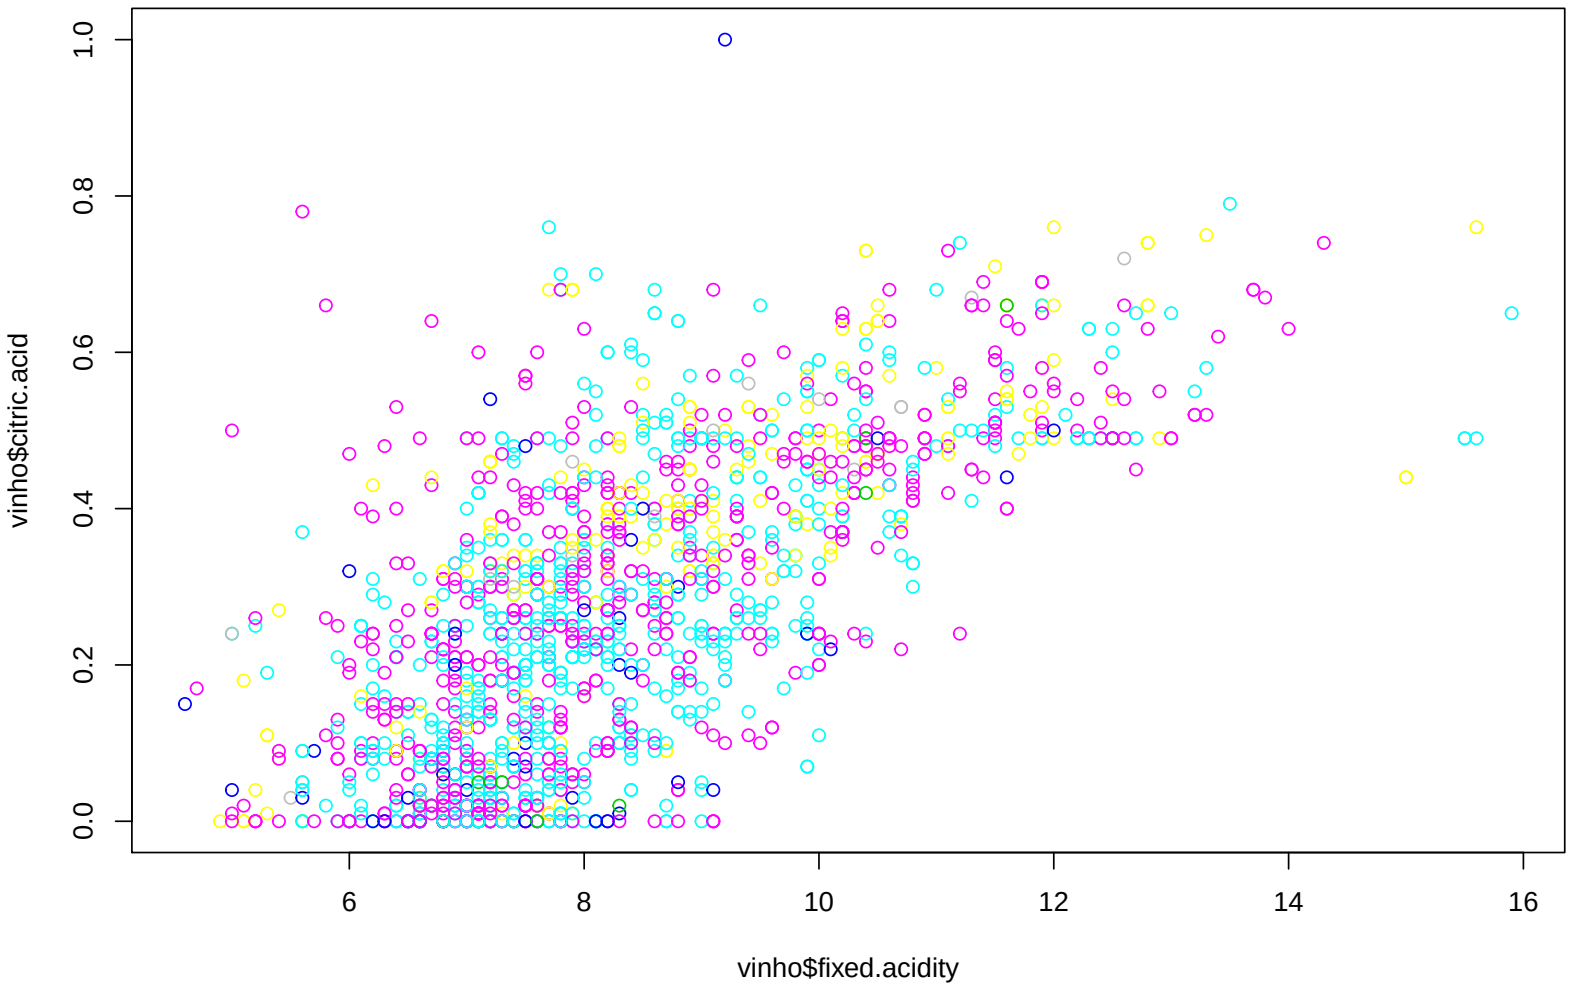

vamos olhar para o diagrama de barras da variaável `quality`

```
barplot(table(vinho$quality))
```

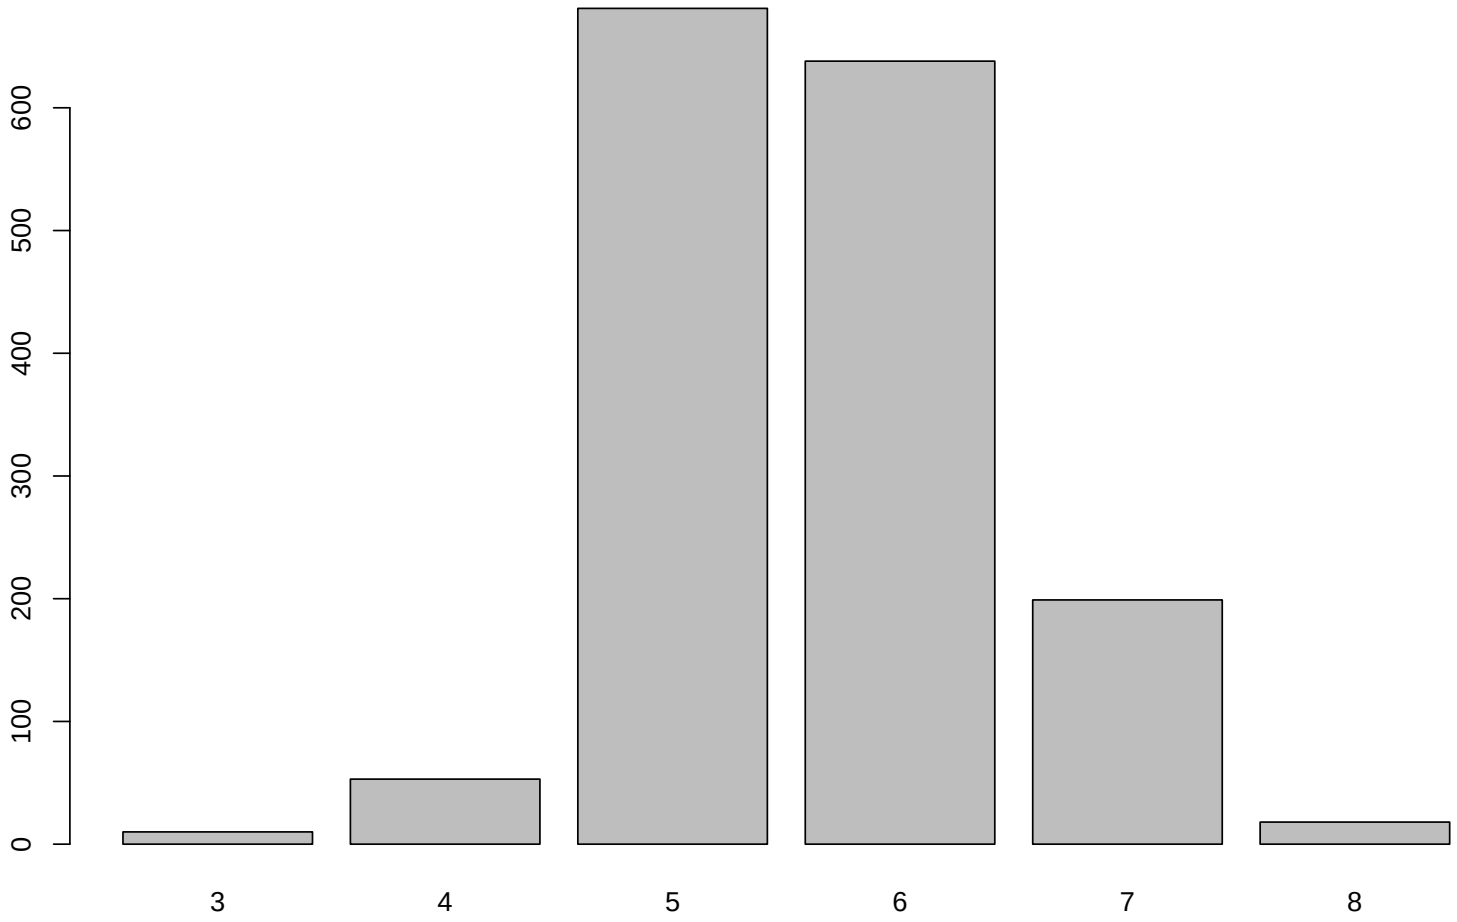

É uma boa prática visualizar a histograma de modo a conhecer a distribuição dos dados quanto a simetria.

```
hist(vinho$fixed.acidity)
```

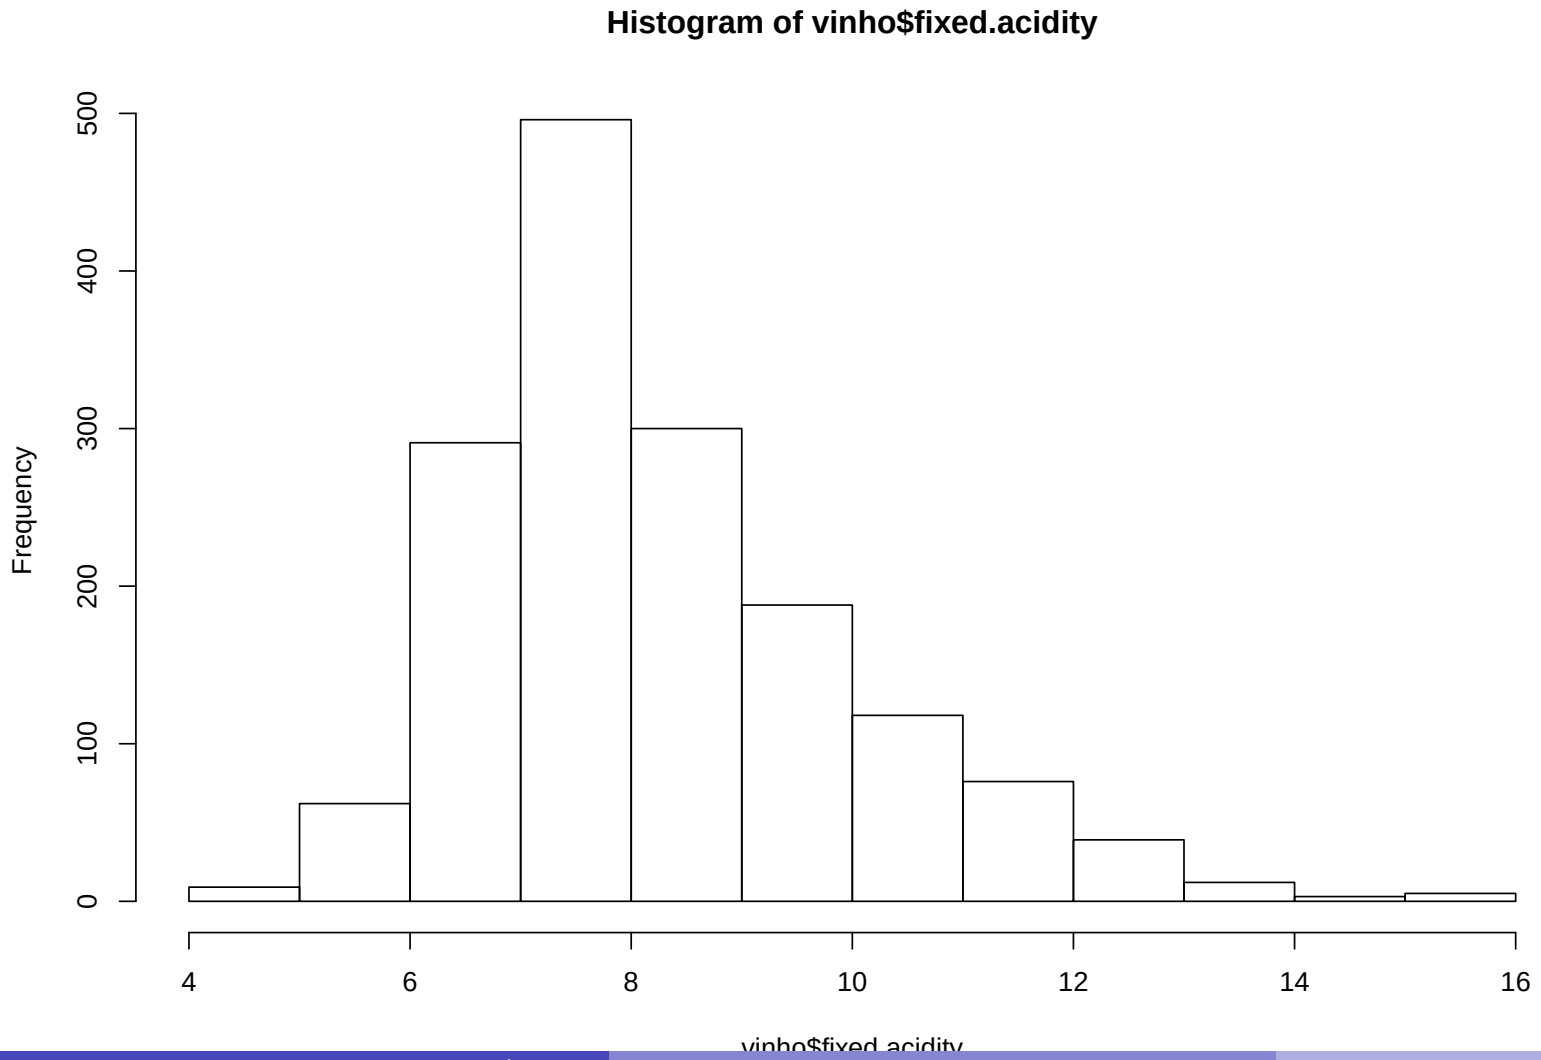

O box plot ajuda mais na identificação de valores atípicos e para comparação.

```
boxplot(vinho$free.sulfur.dioxide)
```

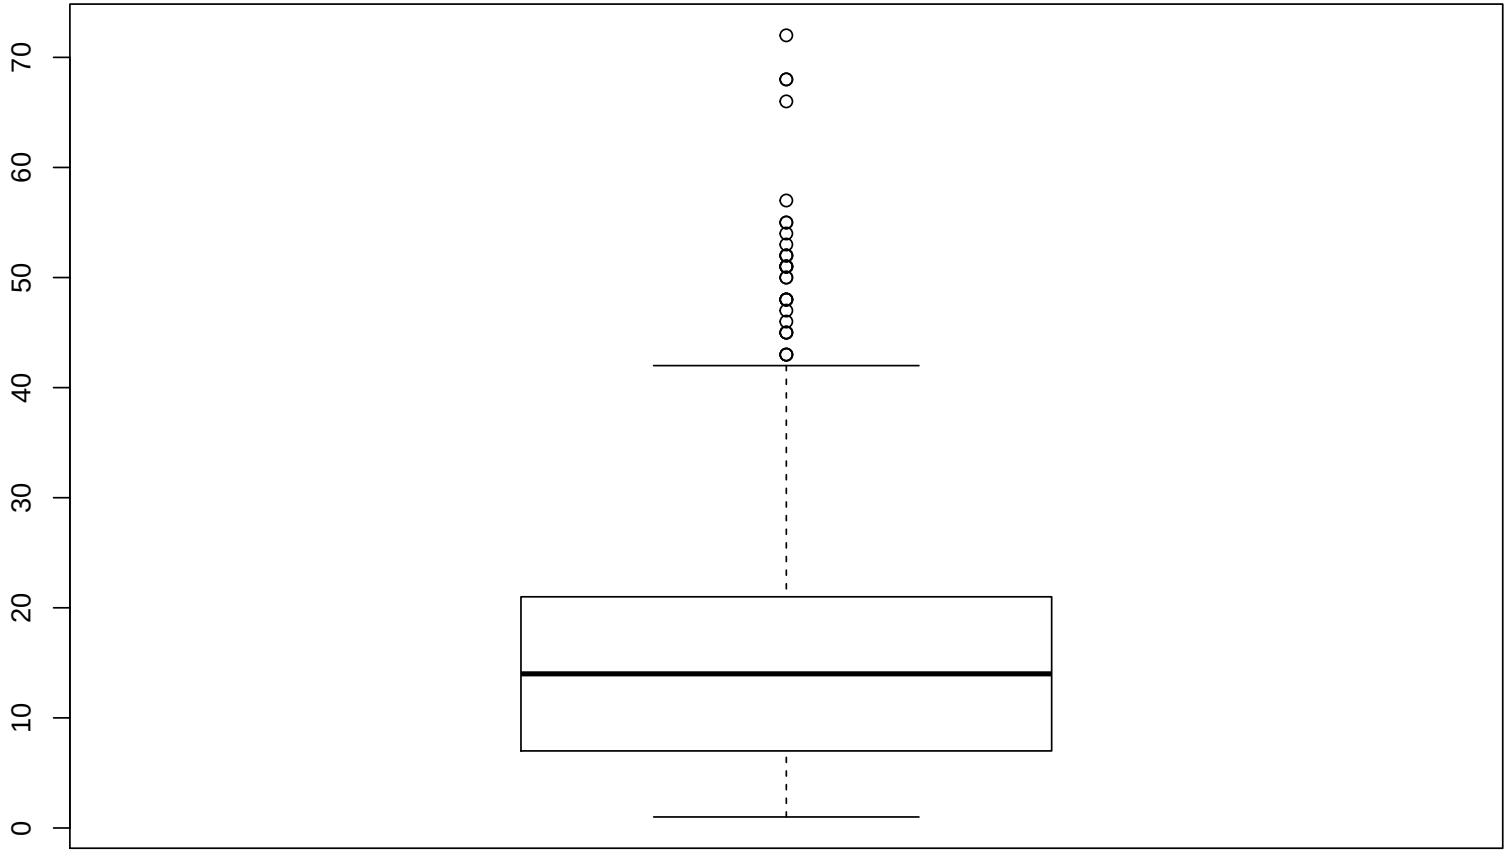
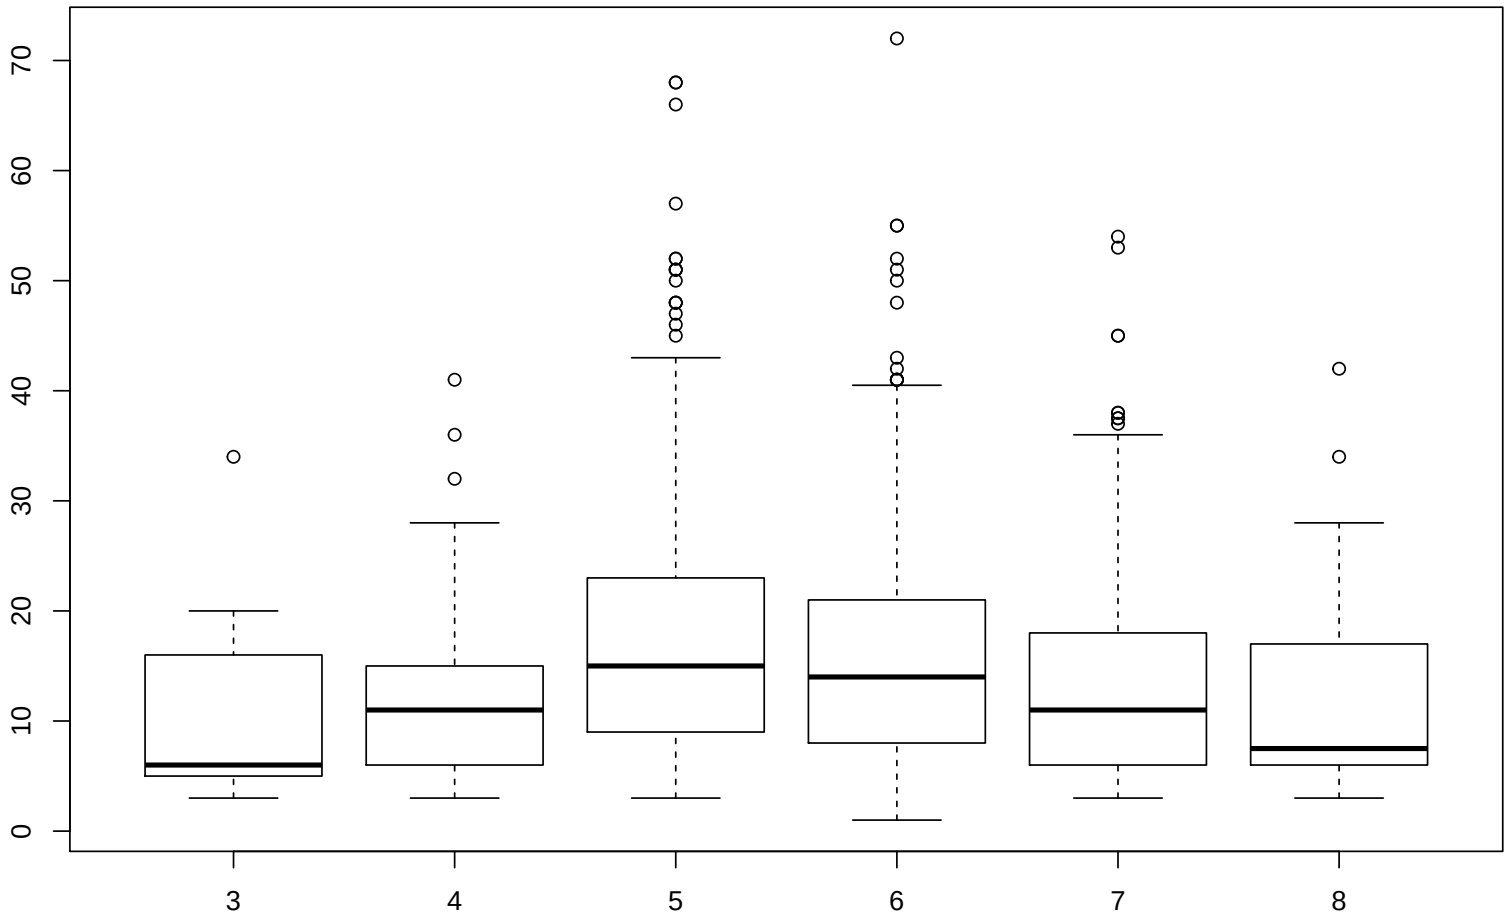
```r
boxplot(vinho$free.sulfur.dioxide~vinho$quality)
```